

7^a
EDICIÓN



DATATÓN

2025

ANTICORRUPCIÓN



SISTEMA NACIONAL
ANTICORRUPCIÓN



Índice de Riesgo por Inconsistencias Patrimoniales (IRIP)

Equipo - Codificados

- ZURISADAI BAUTISTA CASTRO
- MARIANA VIANEY CASTRO MENDEZ
- DAVID ISAI BALAM RODRIGUEZ
- EMIR EDUARDO UC POOT

1. Problema.

La Plataforma Digital Nacional concentra miles de declaraciones patrimoniales, pero gran parte de ellas presentan altos niveles de datos faltantes, valores incongruentes, patrimonios ilógicos, o evoluciones patrimoniales difíciles de rastrear.

Estas inconsistencias dificultan la detección de posibles casos de ocultamiento de bienes, enriquecimiento irregular o manipulación de declaraciones, riesgos vinculados a faltas administrativas (LGRA, artículos 52–61), etc. El propósito de este reto es identificar **cambios incrementales fuera del rango de percepción de ingresos o patrimonio** para apoyar a la investigación anticorrupción.

Sin embargo, la información disponible presenta desafíos como:

- Declaraciones patrimoniales con **alto nivel de datos faltantes** (hasta 95% en variables clave).
- El volumen del dataset es significativo (**16,047 archivos JSON**), lo que dificulta un análisis manual o tradicional.
- Estructura de ingresos compleja (sueldo, profesional, industrial, financiero, otros).
- Inconsistencias entre el total declarado y la suma de los ingresos.
- Declaraciones sin patrimonio declarado, incluso en servidores con altos ingresos.

2. Objetivo General.

Diseñar y desarrollar un **Índice de Riesgo por Inconsistencias Patrimoniales** que permita detectar anomalías e indicios de riesgo de declaraciones con señales de alerta relacionadas con patrimonios e ingresos **atípicos, inconsistentes o potencialmente riesgosos**, usando los datos públicos del Sistema 1 de la PDN, combinando la minería de datos, reglas anticorrupción y análisis estadístico.

3. Objetivos Específicos.

1. **Integrar, depurar y estandarizar** los datos JSON del Sistema 1 de la PDN, considerando limitaciones computacionales mediante muestreo del 10%.
2. **Construir variables derivadas (features)** orientadas a auditoría: proporciones de ingresos, indicadores de patrimonio, conteo de nulos, valores críticos y banderas rojas.
3. **Aplicar métodos de detección de anomalías (Isolation Forest)** para identificar patrones fuera de la distribución normal del dataset.
4. **Diseñar y calcular un índice de riesgo anticorrupción (IRIP)** basado en:
 - Congruencia económica
 - Completitud
 - Coherencia interna
 - Reglas anticorrupción
5. **Clasificar a los servidores públicos:** en riesgo bajo, medio y alto, priorizando casos relevantes para auditoría.
6. **Generar visualizaciones y un dataset final:** apto para tablero, análisis exploratorio o sistemas institucionales futuros.

4. Metodología.

4.1. Recolección y Muestreo

- Carga de 16,047 declaraciones JSON.
- Por restricciones de RAM, se trabajará inicialmente con una muestra aleatoria del 10%, equivalente a ~695,813 registros (dato verificado en metadata).
- El pipeline es replicable al **100%** para obtener resultados finales.

Para cada archivo de la muestra:

- Se carga el contenido con `json.load`.
- Cada archivo contiene una lista de declaraciones; se itera sobre cada declaración para extraer únicamente los campos relevantes.
- Esto permite construir una lista de filas con las variables de interés para cada persona servidora pública.

4.2. Limpieza y Preparación

1. Normalización de tipos y columnas numéricas

- Se definió una lista de columnas numéricas potenciales (`num_cols`) que incluye ingresos, totales patrimoniales y, cuando están presentes, `total_ingresos`, `patrimonio_bruto` y `patrimonio_neto`.
- Solo se conservaron en `num_cols` las columnas que realmente existen en `data`.

2. Limpieza de la columna `año` y creación de `suelo`

- `año` se convirtió a numérico con manejo de errores (`errors='coerce'`), asignando `NaN` a valores no válidos.
- Se filtraron años fuera del rango, asignándoles `NaN`.
- Se creó la columna `suelo` como copia de `ingreso_neto` cuando esta columna existe.

3. Manejo de valores negativos en variables numéricas

- Para cada columna en `num_cols`: se generó una bandera `flag_neg_<col>` que vale 1 si el valor es negativo, 0 en caso contrario.
- Los valores negativos se reemplazaron por `NaN` para evitar distorsionar las métricas.
- A partir de estas banderas, se creó `flag_valor_negativo` como un indicador global (1 si hay al menos un valor negativo en el registro, 0 en caso contrario).

4. Cálculo de porcentaje de nulos en patrimonio

- Se definió un subconjunto de columnas patrimoniales: `patrimonio_bruto`, `patrimonio_neto`, `inmuebles_total`, `vehiculos_total`, `muebles_total`, `adeudos_total` (cuando existen).
- Se calculó `pct_nulos_patrimonio` como la proporción de valores nulos en estas columnas para cada registro.

4.3. Reglas de riesgo (banderas de inconsistencia)

Sobre el `DataFrame data` se definieron varias banderas lógicas para capturar patrones de riesgo:

1. **Ingreso alto + patrimonio en cero**
 - Se calculó `total_ingresos` (solo donde `total_ingresos > 0`).
 - La bandera `flag_ingreso_alto_patrimonio_cero` se activa (1) cuando:
 - `total_ingresos` \geq umbral de ingreso alto, y `patrimonio_bruto` es 0 o nulo (se considera 0 tras `fillna(0)`).
2. **Declaración casi vacía en patrimonio**
 - Se definió `flag_declaracion_casi_vacia` como 1 cuando `pct_nulos_patrimonio` \geq 0.9, es decir, cuando **más del 90%** del patrimonio está vacío o no declarado.
3. **Declaración con todo en cero (ingresos + patrimonio)**
 - Se construyó una lista de columnas de ingreso (`ing_cols`) y se usaron las columnas patrimoniales (`pat_cols`).
 - La bandera `flag_todo_cero` se activa cuando:
 - Todos los ingresos (`ing_cols`) son 0 o nulos, y
 - Todos los componentes de patrimonio (`pat_cols`) son 0 o nulos.
4. **Cambios bruscos entre declaraciones del mismo ID**
 - Se ordena la información por `id` y `anio`.
 - Para las columnas `total_ingresos` y `patrimonio_bruto` (si existen), se calculó el cambio porcentual año a año por persona (`groupby('id').pct_change()`), generando columnas del tipo `pct_cambio_total_ingresos`.
 - Se crearon banderas específicas `flag_brusco_<col>` que se activan cuando el cambio absoluto es mayor al 200% (`abs(pct_cambio) > 2.0`).
 - La bandera global `flag_cambio_brusco` se activa cuando al menos una de estas banderas específicas es 1.

4.4. Transformaciones logarítmicas y selección de variables para el modelo

Para estabilizar escalas y reducir el impacto de valores extremos, se aplicaron transformaciones logarítmicas seguras (`np.log1p`) sobre las columnas numéricas patrimoniales y de ingresos totales:

- `total_ingresos_log`
- `patrimonio_bruto_log`
- `patrimonio_netto_log`
- `inmuebles_total_log`
- `vehiculos_total_log`
- `muebles_total_log`
- `adeudos_total_log`

Posteriormente se definió el conjunto de variables de entrada del modelo:

1. Variables transformadas (`log_cols_modelo`): todos los campos `*_log`.
2. Variables de banderas e indicadores (`flag_cols_modelo`):
 - `flag_ingreso_alto_patrimonio_cero`
 - `flag_declaracion_casi_vacia`
 - `flag_todo_cero`
 - `flag_valor_negativo`
 - `flag_cambio_brusco`
 - `pct_nulos_patrimonio`

4.5. Modelo de riesgo: Isolation Forest

Para la detección de anomalías se construyó un pipeline con:

- `SimpleImputer`
- `StandardScaler`
- `IsolationForest` (`n_estimators=200`, `contamination=0.05`)

El modelo asignó un score de anomalía a cada registro, posteriormente normalizado a escala 0–100 (`riesgo_score`).

Se clasificaron los niveles de riesgo en:

- Bajo (<50)
- Medio (50–79)
- Alto (≥80)

4.6. Generación de salidas para dashboard y metadatos

1. Exportación de resultados a CSV

Se guardó un CSV con todas las columnas del `DataFrame` (`resultados_anticorrupcion_v2.csv`), y posteriormente se generó una versión orientada al dashboard (`resultados_anticorrupcion.csv`), incluyendo:

- Identificadores (id, nombre, apellidos, institución, cargo, año).
- Variables clave (`ingreso_cargo`, `otros_ingresos`, `total_ingresos`, `patrimonio_bruto`).
- Proporción de otros ingresos sobre el total (`prop_otros_ingresos`).
- Puntajes y niveles de riesgo (`riesgo_score`, `riesgo_nivel`, `riesgo_modelo`, `anomaly_iforest`).
- Se incluyó una estructura de reglas anticorrupción (`R1...R10`) y un puntaje adicional (`score_reglas`) para versiones futuras.
- Estructura para futuras reglas R1–R10 (`score_reglas`, `R1_...`, `R2_...`, ..., `R10_...`), inicializadas en esta versión en 0 o NaN para evitar errores en el dashboard.

Se generó un CSV final con variables clave, puntajes y niveles de riesgo, listo para dashboard y se creó un archivo `metadata_riesgo.json` que documenta:

- fecha del análisis
- porcentaje de muestra
- columnas usadas por el modelo
- distribución final de los niveles de riesgo

5. Resultados Principales.

Los resultados obtenidos permiten identificar patrones de riesgo patrimonial mediante la combinación de análisis estadístico, banderas lógicas y detección de anomalías. Con base en la muestra analizada (~10% de las declaraciones del Sistema 1), se obtuvieron los siguientes hallazgos:

1. Completitud de la información

- Entre 80% y 95% de los registros presentan información patrimonial incompleta o totalmente nula.
- La variable `pct_nulos_patrimonio` confirma que el 90% de las declaraciones carecen de datos suficientes para evaluar patrimonio de manera tradicional.

2. Señales de alerta identificadas

El sistema detectó patrones relevantes como:

- Ingreso alto sin patrimonio declarado (`flag_ingreso_alto_patrimonio_cero`).
- Declaraciones casi vacías (`flag_declaracion_casi_vacia`).
- Declaraciones con todos los valores en cero (`flag_todo_cero`).
- Cambios abruptos entre declaraciones consecutivas (`flag_cambio_brusco`).

3. Resultados del modelo

El modelo detectó el 5% de valores atípicos en la muestra, coherente con el nivel de contaminación definido.

Los registros fueron agrupados por nivel de riesgo:

Nivel de riesgo	Casos	Porcentaje
Bajo	654,066	94%
Medio	39,628	5.7%
Alto	2,119	0.3%

6. Conclusiones

1. **La detección de anomalías es viable incluso con datos altamente incompletos.**
El modelo logra identificar patrones inusuales sin depender de información patrimonial completa.
2. **Las banderas lógicas permiten explicar de forma clara dónde están las inconsistencias.**
Esto es esencial para auditores y analistas que requieren interpretabilidad, no solo señales numéricas.
3. **El Índice de Riesgo (basado en Isolation Forest) es una herramienta efectiva de priorización.**
No acusa corrupción, pero sí identifica casos que deben revisarse con mayor atención.
4. **El sistema es escalable y reproducible.** Puede aplicarse al dataset completo del Sistema 1 y adaptarse a otros sistemas de la PDN.
5. **Los hallazgos confirman una problemática estructural: la mayoría de las declaraciones se presentan incompletas.** Dificulta la auditoría tradicional y resalta la necesidad de herramientas como esta.

7. Limitaciones

- **La alta proporción de nulos** en patrimonio limita la precisión del análisis.
- **El modelo depende únicamente de la información declarada**, sin cruces con otros sistemas (contrataciones, intereses, empresas, etc.).
- **El 10% de muestra** —aunque representativo— no sustituye el análisis total del dataset completo.
- **Los resultados son probabilísticos**, no deterministas; el modelo identifica riesgo, no culpabilidad.
- **Las reglas anticorrupción aún no están integradas completamente** en la versión actual del modelo (preparadas pero sin afectar el score final).

8. Trabajos Futuros

- Integrar información de contrataciones (Sistema 6).
- Asociar empresas vinculadas a familiares (declaración de intereses).
- Usar modelos de series temporales para evolución patrimonial por año.
- Crear dashboard en Streamlit para SESNA.